

Klasifikacija slika pasa i mačaka primenom dubokog učenja

Alma Hodžić, Mina Ristić

Mašinsko učenje
Matematički fakultet
Univerzitet u Beogradu

September 10, 2026

Sadržaj

Uvod

Skup podataka

Baseline model

Transfer learning

Fine-tuning

Rezultati

Interpretabilnost

Demonstracija

Zaključak

Uvod

- Cilj projekta je binarna klasifikacija slika pasa i mačaka primenom konvolutivnih neuronskih mreža.

Uvod

- ▶ Cilj projekta je binarna klasifikacija slika pasa i mačaka primenom konvolutivnih neuronskih mreža.
- ▶ Implementirana su i upoređena tri pristupa rastuće složenosti:

Uvod

- ▶ Cilj projekta je binarna klasifikacija slika pasa i mačaka primenom konvolutivnih neuronskih mreža.
- ▶ Implementirana su i upoređena tri pristupa rastuće složenosti:
 - ▶ baseline CNN (VGG-6) treniran od nule

Uvod

- ▶ Cilj projekta je binarna klasifikacija slika pasa i mačaka primenom konvolutivnih neuronskih mreža.
- ▶ Implementirana su i upoređena tri pristupa rastuće složenosti:
 - ▶ baseline CNN (VGG-6) treniran od nule
 - ▶ transfer learning sa VGG-16 mrežom treniranom na ImageNet skupu

Uvod

- ▶ Cilj projekta je binarna klasifikacija slika pasa i mačaka primenom konvolutivnih neuronskih mreža.
- ▶ Implementirana su i upoređena tri pristupa rastuće složenosti:
 - ▶ baseline CNN (VGG-6) treniran od nule
 - ▶ transfer learning sa VGG-16 mrežom treniranom na ImageNet skupu
 - ▶ fine-tuning poslednjeg konvolucionog bloka VGG-16 mreže

Uvod

- ▶ Cilj projekta je binarna klasifikacija slika pasa i mačaka primenom konvolutivnih neuronskih mreža.
- ▶ Implementirana su i upoređena tri pristupa rastuće složenosti:
 - ▶ baseline CNN (VGG-6) treniran od nule
 - ▶ transfer learning sa VGG-16 mrežom treniranom na ImageNet skupu
 - ▶ fine-tuning poslednjeg konvolucionog bloka VGG-16 mreže
- ▶ Pored performansi, analizirana je i **interpretabilnost** modela — vizualizacija međuslojnih aktivacija i Grad-CAM.

Uvod

- ▶ Cilj projekta je binarna klasifikacija slika pasa i mačaka primenom konvolutivnih neuronskih mreža.
- ▶ Implementirana su i upoređena tri pristupa rastuće složenosti:
 - ▶ baseline CNN (VGG-6) treniran od nule
 - ▶ transfer learning sa VGG-16 mrežom treniranom na ImageNet skupu
 - ▶ fine-tuning poslednjeg konvolucionog bloka VGG-16 mreže
- ▶ Pored performansi, analizirana je i **interpretabilnost** modela — vizualizacija međuslojnih aktivacija i Grad-CAM.
- ▶ Projekat je inspirisan radom *Lin, Household Animals Classification Using Deep Learning*, Stanford CS230, 2020.

Skup podataka — Dogs vs. Cats

- ▶ **25.000** označenih slika: 12.500 mačaka i 12.500 pasa — savršeno balansiran skup.

Skup podataka — Dogs vs. Cats

- ▶ **25.000** označenih slika: 12.500 mačaka i 12.500 pasa — savršeno balansiran skup.
- ▶ Slike su prikupljene sa interneta, pa su vrlo raznolike:
 - ▶ širina 42–1050 px (prosek 404)
 - ▶ visina 32–768 px (prosek 360)

Skup podataka — Dogs vs. Cats

- ▶ **25.000** označenih slika: 12.500 mačaka i 12.500 pasa — savršeno balansiran skup.
- ▶ Slike su prikupljene sa interneta, pa su vrlo raznolike:
 - ▶ širina 42–1050 px (prosek 404)
 - ▶ visina 32–768 px (prosek 360)
- ▶ Provereno: **0 oštećenih** fajlova, svih 25.000 u RGB formatu.

Skup podataka — Dogs vs. Cats

- ▶ **25.000** označenih slika: 12.500 mačaka i 12.500 pasa — savršeno balansiran skup.
- ▶ Slike su prikupljene sa interneta, pa su vrlo raznolike:
 - ▶ širina 42–1050 px (prosek 404)
 - ▶ visina 32–768 px (prosek 360)
- ▶ Provereno: **0 oštećenih** fajlova, svih 25.000 u RGB formatu.
- ▶ Sve slike se skaliraju na $224 \times 224 \times 3$ — ulaznu dimenziju VGG-16 mreže.




Podela podataka

Skup	Slika	Mačke	Psi
Train	20.000	10.000	10.000
Validation	4.000	2.000	2.000
Test	1.000	500	500
Ukupno	25.000	12.500	12.500


- ▶ Podela je **stratifikovana**, sa fiksiranim seed-om 42.
- ▶ Napravljena je **jednom** i sačuvana u `split.csv` — svi modeli koriste identične podatke, pa je poređenje pošteno.

Baseline — VGG-6 treniran od nule




- 4 bloka Conv2D + MaxPooling2D, filteri 3×3 , broj filtera raste $32 \rightarrow 64 \rightarrow 128 \rightarrow 128$.

Baseline — VGG-6 treniran od nule




- ▶ 4 bloka Conv2D + MaxPooling2D, filteri 3×3 , broj filtera raste $32 \rightarrow 64 \rightarrow 128 \rightarrow 128$.
- ▶ Ukupno **13.086.913** parametara.

Baseline — VGG-6 treniran od nule




- ▶ 4 bloka Conv2D + MaxPooling2D, filteri 3×3 , broj filtera raste $32 \rightarrow 64 \rightarrow 128 \rightarrow 128$.
- ▶ Ukupno **13.086.913** parametara.
- ▶ **98 %** svih parametara je u jednom sloju — Dense(512) posle Flatten-a (12.845.568).

Baseline — VGG-6 treniran od nule



- ▶ 4 bloka Conv2D + MaxPooling2D, filteri 3×3 , broj filtera raste $32 \rightarrow 64 \rightarrow 128 \rightarrow 128$.
- ▶ Ukupno **13.086.913** parametara.
- ▶ **98 %** svih parametara je u jednom sloju — Dense(512) posle Flatten-a (12.845.568).
- ▶ Baš ta koncentracija kapaciteta je razlog zašto model lako **overfituje**.

Baseline — VGG-6 treniran od nule



- ▶ 4 bloka Conv2D + MaxPooling2D, filteri 3×3 , broj filtera raste $32 \rightarrow 64 \rightarrow 128 \rightarrow 128$.
- ▶ Ukupno **13.086.913** parametara.
- ▶ **98 %** svih parametara je u jednom sloju — Dense(512) posle Flatten-a (12.845.568).
- ▶ Baš ta koncentracija kapaciteta je razlog zašto model lako **overfituje**.
- ▶ Optimizator: RMSprop, $1r = 1e-4$; gubitak: Binary Crossentropy.

Baseline bez regularizacije — demonstracija overfitovanja




Figure: 20 epoha, bez EarlyStopping-a — namerno, da se overfitovanje vidi u celosti

- ▶ Train accuracy **99,66 %**, validation accuracy **83,4 %** — jaz od preko 16 poena.
- ▶ Validation loss **raste** sa 0,36 na 0,91 dok train loss pada ka nuli.

Baseline sa regularizacijom





Figure: Data augmentation + Dropout(0.5) + EarlyStopping


- ▶ Isti optimizator i ista stopa učenja — razlika dolazi **isključivo** od regularizacije.
- ▶ Krive ostaju blizu jedna drugoj: **test accuracy 90,30 %**.

Transfer learning sa VGG-16




- VGG-16 sa ImageNet težinama, `include_top=False` — originalni klasifikator se odbacuje.

Transfer learning sa VGG-16




- ▶ VGG-16 sa ImageNet težinama, `include_top=False` — originalni klasifikator se odbacuje.
- ▶ **Zašto zamrznuta baza:** nova glava ima nasumične težine i proizvodi ogromne gradijente koji bi u prvim koracima uništili naučene ImageNet težine.

Transfer learning sa VGG-16




- ▶ VGG-16 sa ImageNet težinama, `include_top=False` — originalni klasifikator se odbacuje.
- ▶ **Zašto zamrznuta baza:** nova glava ima nasumične težine i proizvodi ogromne gradijente koji bi u prvim koracima uništili naučene ImageNet težine.
- ▶ **GlobalAveragePooling** umesto Flatten-a — inače bi glava opet imala milione parametara.

Transfer learning sa VGG-16





- ▶ VGG-16 sa ImageNet težinama, `include_top=False` — originalni klasifikator se odbacuje.
- ▶ **Zašto zamrznuta baza:** nova glava ima nasumične težine i proizvodi ogromne gradijente koji bi u prvim koracima uništili naučene ImageNet težine.
- ▶ **GlobalAveragePooling** umesto Flatten-a — inače bi glava opet imala milione parametara.
- ▶ Trenira se svega **131.585** od 14.846.273 parametara — **manje od 1%**.

Transfer learning sa VGG-16



- ▶ VGG-16 sa ImageNet težinama, `include_top=False` — originalni klasifikator se odbacuje.
- ▶ **Zašto zamrznuta baza:** nova glava ima nasumične težine i proizvodi ogromne gradijente koji bi u prvim koracima uništili naučene ImageNet težine.
- ▶ **GlobalAveragePooling** umesto Flatten-a — inače bi glava opet imala milione parametara.
- ▶ Trenira se svega **131.585** od 14.846.273 parametara — **manje od 1 %**.
- ▶ Adam, `lr = 1e-3`, EarlyStopping i ReduceLROnPlateau.

Transfer learning — tok treninga



- ▶ Već posle **prve epohe** validation accuracy je **98,52 %**.
- ▶ EarlyStopping staje u 6. epohi i vraća težine iz 3. epohe (najbolji val_loss).
- ▶ **Test accuracy: 98,10 %** — broj grešaka pao je sa 97 na 19.

Fine-tuning VGG-16 modela

- ▶ Polazi se od sačuvanog transfer learning modela — ne trenira se ništa iznova.

Fine-tuning VGG-16 modela

- ▶ Polazi se od sačuvanog transfer learning modela — ne trenira se ništa iznova.
- ▶ Odmrznut je **samo poslednji konvolucioni blok** (block5_conv1/2/3):

Fine-tuning VGG-16 modela

- ▶ Polazi se od sačuvanog transfer learning modela — ne trenira se ništa iznova.
- ▶ Odmrznut je **samo poslednji konvolucioni blok** (block5_conv1/2/3):
 - ▶ niži slojevi uče **univerzalne** karakteristike (ivice, teksture) — nema šta da se popravi, a ima šta da se pokvari

Fine-tuning VGG-16 modela

- ▶ Polazi se od sačuvanog transfer learning modela — ne trenira se ništa iznova.
- ▶ Odmrznut je **samo poslednji konvolucioni blok** (block5_conv1/2/3):
 - ▶ niži slojevi uče **univerzalne** karakteristike (ivice, teksture) — nema šta da se popravi, a ima šta da se pokvari
 - ▶ viši slojevi uče **semantiku specifičnu za ImageNet** — tu prilagođavanje ima smisla

Fine-tuning VGG-16 modela

- ▶ Polazi se od sačuvanog transfer learning modela — ne trenira se ništa iznova.
- ▶ Odmrznut je **samo poslednji konvolucioni blok** (block5_conv1/2/3):
 - ▶ niži slojevi uče **univerzalne** karakteristike (ivice, teksture) — nema šta da se popravi, a ima šta da se pokvari
 - ▶ viši slojevi uče **semantiku specifičnu za ImageNet** — tu prilagođavanje ima smisla
 - ▶ odmrzavanje cele baze značilo bi 14,7 miliona parametara na 20.000 slika

Fine-tuning VGG-16 modela

- ▶ Polazi se od sačuvanog transfer learning modela — ne trenira se ništa iznova.
- ▶ Odmrznut je **samo poslednji konvolucioni blok** (block5_conv1/2/3):
 - ▶ niži slojevi uče **univerzalne** karakteristike (ivice, teksture) — nema šta da se popravi, a ima šta da se pokvari
 - ▶ viši slojevi uče **semantiku specifičnu za ImageNet** — tu prilagođavanje ima smisla
 - ▶ odmrzavanje cele baze značilo bi 14,7 miliona parametara na 20.000 slika
- ▶ Trenabilnih parametara: **7.211.009**; zamrznutih: 7.635.264.



Fine-tuning VGG-16 modela

- ▶ Polazi se od sačuvanog transfer learning modela — ne trenira se ništa iznova.
- ▶ Odmrznut je **samo poslednji konvolucioni blok** (block5_conv1/2/3):
 - ▶ niži slojevi uče **univerzalne** karakteristike (ivice, teksture) — nema šta da se popravi, a ima šta da se pokvari
 - ▶ viši slojevi uče **semantiku specifičnu za ImageNet** — tu prilagođavanje ima smisla
 - ▶ odmrzavanje cele baze značilo bi 14,7 miliona parametara na 20.000 slika
- ▶ Trenabilnih parametara: **7.211.009**; zamrznutih: 7.635.264.
- ▶ Stopa učenja **1e-5** — sto puta manja nego u prethodnoj fazi, jer se sada menjaju težine koje su **već dobre** (rizik od katastrofalnog zaboravljanja).

Fine-tuning VGG-16 modela


- ▶ Polazi se od sačuvanog transfer learning modela — ne trenira se ništa iznova.
- ▶ Odmrznut je **samo poslednji konvolucioni blok** (block5_conv1/2/3):
 - ▶ niži slojevi uče **univerzalne** karakteristike (ivice, teksture) — nema šta da se popravi, a ima šta da se pokvari
 - ▶ viši slojevi uče **semantiku specifičnu za ImageNet** — tu prilagođavanje ima smisla
 - ▶ odmrzavanje cele baze značilo bi 14,7 miliona parametara na 20.000 slika
- ▶ Trenabilnih parametara: **7.211.009**; zamrznutih: 7.635.264.
- ▶ Stopa učenja **1e-5** — sto puta manja nego u prethodnoj fazi, jer se sada menjaju težine koje su **već dobre** (rizik od katastrofalnog zaboravljanja).
- ▶ Model se mora **ponovo kompajlirati** da bi Keras primetio promenu trainable statusa.

Fine-tuning — tok treninga



- ▶ Najbolji `val_loss` već u **2. epohi** (0,0267).
- ▶ Zatim `train accuracy` raste, a `val_loss` se pogoršava — početak overfitovanja; `EarlyStopping` staje u 5. epohi i vraća težine iz 2.
- ▶ **Test accuracy: 99,00 %.**

Poređenje modela na test skupu



Model	Accuracy	Precision	Recall	F1	Grešaka
Baseline VGG-6	90,30 %	89,74 %	91,00 %	90,37 %	97
VGG-16 Transfer Learning	98,10 %	98,39 %	97,80 %	98,09 %	19
VGG-16 Fine-tuning	99,00 %	99,00 %	99,00 %	99,00 %	10

Matrice konfuzije




Figure: Baseline | Transfer learning | Fine-tuning

- ▶ Greške su u sva tri modela **simetrične** — nema pristrasnosti ka jednoj klasi.
- ▶ Kod finalnog modela po **5 grešaka** sa svake strane, pa su sve četiri metrike identične.
- ▶ **Ograničenje:** razlika 98,10 % naspram 99,00 % je 9 slika od 1.000 — nije statistički čvrsto dokazana.

Interpretabilnost — međuslojne aktivacije

- ▶ Model sa 99 % tačnosti i dalje može biti tačan **iz pogrešnog razloga** (klasifikator vukova koji je detektovao sneg u pozadini).
- ▶ Dva komplementarna pristupa: **aktivacije** — šta mreža računa; **Grad-CAM** — zašto je odlučila baš tako.






Figure: Prvi (gore) i treći (dole) konvolucionni sloj: detektori ivica → apstraktne reprezentacije

Retkost (sparsity) aktivacija po sloju




- Udeo tačnih nula (posledica ReLU aktivacije) raste sa dubinom: **38–41 %** u prvom sloju do **86–87 %** u poslednjem.

Retkost (sparsity) aktivacija po sloju



- ▶ Udeo tačnih nula (posledica ReLU aktivacije) raste sa dubinom: **38–41 %** u prvom sloju do **86–87 %** u poslednjem.
- ▶ Gotovo **identično za obe klase** — dakle opšte svojstvo mreže, a ne nešto specifično za mačke i pse.

Retkost (sparsity) aktivacija po sloju



- ▶ Udeo tačnih nula (posledica ReLU aktivacije) raste sa dubinom: **38–41 %** u prvom sloju do **86–87 %** u poslednjem.
- ▶ Gotovo **identično za obe klase** — dakle opšte svojstvo mreže, a ne nešto specifično za mačke i pse.
- ▶ Uočen je i jedan potpuno neaktivan filter — verovatno *dead ReLU*.

Grad-CAM — kako radi

- *Gradient-weighted Class Activation Mapping* (Selvaraju i sar., 2017) — toplotna mapa oblasti koje su najviše doprinele konkretnoj odluci.

Grad-CAM — kako radi

- ▶ *Gradient-weighted Class Activation Mapping* (Selvaraju i sar., 2017) — toplotna mapa oblasti koje su najviše doprinele konkretnoj odluci.
- ▶ Postupak:
 1. uzme se izlaz poslednjeg konvolucionog sloja `block5_conv3` ($14 \times 14 \times 512$)

Grad-CAM — kako radi

- ▶ *Gradient-weighted Class Activation Mapping* (Selvaraju i sar., 2017) — toplotna mapa oblasti koje su najviše doprinele konkretnoj odluci.
- ▶ Postupak:
 1. uzme se izlaz poslednjeg konvolucionog sloja `block5_conv3` ($14 \times 14 \times 512$)
 2. izračunaju se gradijenti skora klase po tim mapama i **prostorno usrednje** — dobija se težina po kanalu

Grad-CAM — kako radi

- ▶ *Gradient-weighted Class Activation Mapping* (Selvaraju i sar., 2017) — toplotna mapa oblasti koje su najviše doprinele konkretnoj odluci.
- ▶ Postupak:
 1. uzme se izlaz poslednjeg konvolucionog sloja `block5_conv3` ($14 \times 14 \times 512$)
 2. izračunaju se gradijenti skora klase po tim mapama i **prostorno usrednje** — dobija se težina po kanalu
 3. težinska suma mapa, pa **ReLU** (zadržavaju se samo pozitivni doprinosi)

Grad-CAM — kako radi

- ▶ *Gradient-weighted Class Activation Mapping* (Selvaraju i sar., 2017) — toplotna mapa oblasti koje su najviše doprinele konkretnoj odluci.
- ▶ Postupak:
 1. uzme se izlaz poslednjeg konvolucionog sloja `block5_conv3` ($14 \times 14 \times 512$)
 2. izračunaju se gradijenti skora klase po tim mapama i **prostorno usrednje** — dobija se težina po kanalu
 3. težinska suma mapa, pa **ReLU** (zadržavaju se samo pozitivni doprinosi)
 4. normalizacija i uveličavanje na dimenzije slike

Grad-CAM — kako radi

- ▶ *Gradient-weighted Class Activation Mapping* (Selvaraju i sar., 2017) — toplotna mapa oblasti koje su najviše doprinele konkretnoj odluci.
- ▶ Postupak:
 1. uzme se izlaz poslednjeg konvolucionog sloja `block5_conv3` ($14 \times 14 \times 512$)
 2. izračunaju se gradijenti skora klase po tim mapama i **prostorno usrednje** — dobija se težina po kanalu
 3. težinska suma mapa, pa **ReLU** (zadržavaju se samo pozitivni doprinosi)
 4. normalizacija i uveličavanje na dimenzije slike
- ▶ Dve implementacione odluke:

Grad-CAM — kako radi


- ▶ *Gradient-weighted Class Activation Mapping* (Selvaraju i sar., 2017) — toplotna mapa oblasti koje su najviše doprinele konkretnoj odluci.
- ▶ Postupak:
 1. uzme se izlaz poslednjeg konvolucionog sloja `block5_conv3` ($14 \times 14 \times 512$)
 2. izračunaju se gradijenti skora klase po tim mapama i **prostorno usrednje** — dobija se težina po kanalu
 3. težinska suma mapa, pa **ReLU** (zadržavaju se samo pozitivni doprinosi)
 4. normalizacija i uveličavanje na dimenzije slike
- ▶ **Dve implementacione odluke:**
 - ▶ Grad-CAM se računa nad **logitom**, ne nad izlazom sigmoide — kod sigurnih predikcija sigmoida je zasićena i gradijenti bi nestali

Grad-CAM — kako radi


- ▶ *Gradient-weighted Class Activation Mapping* (Selvaraju i sar., 2017) — toplotna mapa oblasti koje su najviše doprinele konkretnoj odluci.
- ▶ Postupak:
 1. uzme se izlaz poslednjeg konvolucionog sloja `block5_conv3` ($14 \times 14 \times 512$)
 2. izračunaju se gradijenti skora klase po tim mapama i **prostorno usrednje** — dobija se težina po kanalu
 3. težinska suma mapa, pa **ReLU** (zadržavaju se samo pozitivni doprinosi)
 4. normalizacija i uveličavanje na dimenzije slike
- ▶ **Dve implementacione odluke:**
 - ▶ Grad-CAM se računa nad **logitom**, ne nad izlazom sigmoide — kod sigurnih predikcija sigmoidida je zasićena i gradijenti bi nestali
 - ▶ za klasu `cat` koristi se —**logit**, jer jedini izlazni neuron meri „koliko je ovo pas”

Grad-CAM — rezultati

Grad-CAM | stvarna: cat | predikcija: cat




Grad-CAM | stvarna: dog | predikcija: dog



- ▶ Model se fokusira na **glavu, oči i njušku**, a pozadina ostaje hladna.
- ▶ Odluke se zasnivaju na samoj životinji — **nema „Clever Hans” efekta**.
- ▶ **Ograničenje:** analiza je kvalitativna, na šest primera; za tvrd zaključak bila bi potrebna kvantitativna mera nad celim test skupom.

Demo — kompletan tok


Grad-CAM | prava: dog | predikcija: dog (100.00%)



- ▶ Učitavanje finalnog modela `vgg16_finetuned.keras`.

Demo — kompletan tok


Grad-CAM | prava: dog | predikcija: dog (100.00%)



- ▶ Učitavanje finalnog modela `vgg16_finetuned.keras`.
- ▶ Slika se skalira na 224×224 i prosleđuje modelu — **bez ručne pripreme**, jer `preprocess_input` radi unutar samog modela.

Demo — kompletan tok


Grad-CAM | prava: dog | predikcija: dog (100.00%)



- ▶ Učitavanje finalnog modela `vgg16_finetuned.keras`.
- ▶ Slika se skalira na 224×224 i prosleđuje modelu — **bez ručne pripreme**, jer `preprocess_input` radi unutar samog modela.
- ▶ Izlaz: predviđena klasa i pouzdanost.

Demo — kompletan tok

Grad-CAM | prava: dog | predikcija: dog (100.00%)



- ▶ Učitavanje finalnog modela `vgg16_finetuned.keras`.
- ▶ Slika se skalira na 224×224 i prosleđuje modelu — **bez ručne pripreme**, jer `preprocess_input` radi unutar samog modela.
- ▶ Izlaz: predviđena klasa i pouzdanost.
- ▶ Grad-CAM objašnjava **zašto** je model tako odlučio.

Zaključak

- ▶ Prethodno naučeno znanje vredi više od kapaciteta modela: transfer learning trenira **100 puta manje parametara** od baseline-a, a smanjuje broj grešaka za **80 %**.

Zaključak

- ▶ Prethodno naučeno znanje vredi više od kapaciteta modela: transfer learning trenira **100 puta manje parametara** od baseline-a, a smanjuje broj grešaka za **80 %**.
- ▶ Fine-tuning poslednjeg bloka donosi dodatno poboljšanje — finalnih **99,00 %** na test skupu.

Zaključak

- ▶ Prethodno naučeno znanje vredi više od kapaciteta modela: transfer learning trenira **100 puta manje parametara** od baseline-a, a smanjuje broj grešaka za **80 %**.
- ▶ Fine-tuning poslednjeg bloka donosi dodatno poboljšanje — finalnih **99,00 %** na test skupu.
- ▶ Jedinствена podela iz `split.csv` omogućila je da se razlike pripišu **modelu**, a ne sreći u podeli podataka.

Zaključak

- ▶ Prethodno naučeno znanje vredi više od kapaciteta modela: transfer learning trenira **100 puta manje parametara** od baseline-a, a smanjuje broj grešaka za **80 %**.
- ▶ Fine-tuning poslednjeg bloka donosi dodatno poboljšanje — finalnih **99,00 %** na test skupu.
- ▶ Jedinstvena podela iz `split.csv` omogućila je da se razlike pripišu **modelu**, a ne sreći u podeli podataka.
- ▶ Interpretabilnost potvrđuje da je model tačan **iz pravog razloga** — gleda životinju, ne pozadinu.

Zaključak

- ▶ Prethodno naučeno znanje vredi više od kapaciteta modela: transfer learning trenira **100 puta manje parametara** od baseline-a, a smanjuje broj grešaka za **80 %**.
- ▶ Fine-tuning poslednjeg bloka donosi dodatno poboljšanje — finalnih **99,00 %** na test skupu.
- ▶ Jedinstvena podela iz `split.csv` omogućila je da se razlike pripišu **modelu**, a ne sreći u podeli podataka.
- ▶ Interpretabilnost potvrđuje da je model tačan **iz pravog razloga** — gleda životinju, ne pozadinu.
- ▶ Pravci za dalji rad: veći test skup ili unakrsna validacija, poređenje sa modernijim arhitekturama, i kvantitativna Grad-CAM analiza.

Hvala na pažnji!